

Análisis de redes sociales: Youtube

Universidad del Valle de Guatemala
Ciencia de Datos, sección 10
Castellanos, I; Pérez, M. y Rodríguez R.

Introducción

A continuación, se presenta un análisis de distintas características de dos conjuntos de datos referentes a videos de Youtube y comentarios de esta misma plataforma. Se aplicará un análisis de sentimiento, análisis del conjunto por medio de redes y la identificación de comunidades dentro de los mismos datos.

Descripción de los datos

Se han proporcionado dos conjuntos de datos obtenidos de Youtube:
youtube_videos.csv (consistente en información de videos y canales) y
youtube_comments.csv (el cuál es un conjunto de comentarios de una selección de videos).

El conjunto de youtube_videos.csv consistía en 293 videos y 20 variables. En las tablas siguientes se tiene un resumen general de la distribución y características de los videos:

Cuadro 1. Resumen general de los videos del conjunto de datos.

Métrica	Cantidad
Videos	293
Canales	97
Comentarios	406
Autores únicos	332
Videos con comentarios	19
Canales con comentarios	8

Cuadro 2. Categoría de videos

Categoría	Frecuencia	Porcentaje
Noticias y política	138	47.1%
Personas y blogs	66	22.52%
Entretenimiento	48	16.38%
Educación	19	6.5%
Viajes y eventos	8	2.73%
Ciencia y tecnología	6	2.05%

Activismo	3	1.02%
Películas y animación	2	0.68%
Comedia	1	0.34%
Deportes	1	0.34%
Música	1	0.34%

Respecto al conjunto youtube_comments.csv, este consta de 406 comentarios y 17 variables. De estos, 30 recibieron una respuesta. Este archivo no tiene comentarios duplicados. Los canales con mayor cantidad de comentarios se presentan en la siguiente tabla:

Cuadro 3. Canales con más comentarios

Canal	Comentarios	Autores únicos	Videos	Respuestas
Quorum	256	214	11	4
Gobierno de la República de Guatemala	70	50	2	15
Noticias Telemundo	25	18	1	13
Municipalidad de Guatemala	25	25	1	16
Noti7	14	13	1	1
PrensaLibreOficial	7	7	1	1
TN23 Guatemala	7	7	1	1
Noticiero Guatevisión 13 Hrs.	2	2	1	0

En cuanto a la relación entre los elementos de los conjuntos de datos se tiene lo siguiente:

- **Canal y video:** un canal puede publicar varios videos, mientras que cada video tiene un solo canal propietario en estos datos. channel_id identifica al canal; channel_name y channel_handle son etiquetas visibles.
- **Video y comentario:** cada comentario está asociado con un video mediante video_id, y un video puede tener ninguno o varios comentarios observados. Que un video no aparezca en comentarios no demuestra que no tenga comentarios en YouTube; puede deberse a la cobertura de la recolección.

- **Autor y comentario:** cada comentario tiene un autor identificado por `author_channel_id`, y un autor puede comentar una o varias veces. En YouTube las cuentas de autores también son canales, pero `author_channel_id` representa al autor del comentario y `channel_id` al propietario del video, por lo que sus roles no deben confundirse.
- **Categoría:** `category` es un atributo del video asignado por YouTube, no del autor ni del comentario. Todos los comentarios heredan la categoría de su video al efectuar la integración.
- **Consulta de búsqueda:** `source_query` documenta cómo se encontró el contenido. No es una clasificación temática definitiva. En videos, `query_hits` puede registrar varias consultas que recuperaron el mismo video; `source_group` distingue la estrategia general de búsqueda.
- **Respuestas:** `reply_count` solo es un conteo. No identifica autores ni relaciones directas entre usuarios.

Red bipartita

Se ha construido una red bipartita no dirigida en la que un conjunto de nodos representa a los autores y el otro conjunto los videos de estos. Los pesos asignados son el número de comentarios publicados por autor en un video. Las aristas se crean en el momento en que un autor comenta en un video. La red creada consiste en 351 nodos con 343 aristas.


A continuación, se muestra la tabla de aristas correspondiente a la red en la Figura 1:

Cuadro 4. Tabla de aristas

Source	target	Autor_channel_id	Autor_name	Autor_handle
autor::UC-HeUTT6_g-VoiWds2a4H-w	video::6W4u8sGEnGM	UC-HeUTT6_g-VoiWds2a4H-w	@JorgeMunoz-gd9et	/@JorgeMunoz-gd9et 6 W
autor::UC-lul5tDYH_oiAMXQH-KaaQ	video::6W4u8sGEnGM	UC-lul5tDYH_oiAMXQH-KaaQ	@AlbertoMancilla-p9h	/@AlbertoMancilla-p9h 6 W

Figura 1. Red bipartita de autores y videos

Red bipartita de autores y videos



En la **Figura 1** se tiene del lado izquierdo los autores y del derecho los videos. Es posible ver que muchos autores comentan en pocos videos. Asimismo, la gran mayoría de los autores tienen una gran cantidad de comentarios. Algunos videos son muy poco comentados, mientras que otros tienen muchos comentarios.


En la red bipartita autor-video, una arista indica que un autor publicó al menos un comentario en un video. El peso de la arista indica el número de comentarios observados del autor en dicho video. Por lo tanto, una arista representa cuantas veces ha participado en el contenido.

Proyecciones de la red

Se han construido dos proyecciones distintas: autor-autor y video-video. En el primero dos autores se conectan si comentan el mismo video; los pesos representan el número de videos compartidos. En el segundo caso dos videos se conectan si comparten al menos un autor; los pesos representan el número de autores compartidos.

La proyección autor-autor ha consistido en 332 nodos y 10732 aristas. En la siguiente figura se observa el gráfico correspondiente:

Figura 2. Proyección autor-autor



Se observa que hay una gran cantidad de autores, los cuales es posible que sean comentadores de un tipo de contenido de masas, lo cual representa la alta acumulación de en medio, mientras que hay otros que comentan en videos un poco más de nicho.

En cuanto a la proyección video-video, esta consta de 19 nodos y 11 aristas. La Figura 3 muestra un gráfico de esta proyección:

Figura 3. Proyección video-video



De lo anterior, se tiene que los videos pueden estar relacionados por el tipo de su contenido.

En la siguiente tabla se muestra la comparación entre ambas proyecciones:

Cuadro 5. Comparación entre las proyecciones

Red	Nodos	Aristas	Densidad
Autor-Autor	332	10732	0.125319
Video-Video	19	11	0.064327

- Autor–autor: Representa si dos autores están relacionados por comentar el mismo contenido; no significa amistad ni interacción directa.
- Video–video: Representa si dos videos se relacionan cuando al menos un mismo autor comentó en ambos.

Una mayor densidad en la red autor–autor indicaría mayor coincidencia entre videos en los que comentan autores. Una mayor densidad video–video indicaría similitudes de audiencias entre videos. Con el fin de mostrar las diferencias entre las tres redes implementadas -Bipartita, Autor-Autor, Video-Video- se procede muestra la siguiente tabla

Cuadro 6. Comparación de métricas de las tres redes.

Red	Nodos	Aristas	Densidad	Grado medio	Componentes	Componente mayor
Bipartita	351	343	0.005584	1.954416	10	286
Autor-Autor	332	10732	0.195319	64.650602	10	276
Video-Video	19	11	0.064327	1.157895	10	10

De la tabla anterior se puede argumentar que bipartita es la que tiene la mayor cantidad de nodos estos en su gran mayoría son de autores que comentan videos. La mayor cantidad de aristas las tiene la red de autor-autor, debido a la alta cantidad de nodos y que estos se pueden conectar con el simple hecho de haber comentado sobre un mismo video, debido a la alta cantidad de aristas, también posee la mayor densidad y grado medio de todas.

Todas las redes tienen 10 componentes, lo cual tiene sentido, teniendo en cuenta que se forma conjuntos aislados por la forma en que se relacionan videos y autores, lo cual hace que en las proyecciones se mantengan estos conjuntos. El componente


más grande de Bipartita contiene al componente más grande de Autor-Autor, junto al componente más grande de Video-Video.

En cuanto a la estructura de las redes se tiene que los nodos de Autor-Autor están más conectados que las otras redes. Solo la red Autor-Autor tiene una alta cantidad de conexiones, teniendo hasta 18 conexiones en su primer cuartil. La red Video-Video, un poco menos de la mitad de sus nodos tiene al menos 2 conexiones. La red Bipartita, la gran mayoría de sus nodos solo tienen una conexión, pero hay nodos muy conectados (estos deberían ser videos).

Comunidades

Se ha elegido implementar esta parte del proceso con la red de videos, ya que esta red puede permitir entender los tipos de contenidos que más comparte una audiencia. Con este se han encontrado 12 comunidades con modularidad 0.4053; es importante mencionar que, de las 12 comunidades, solo 3 son de interés, ya que estas tienen más de un elemento. El que la modularidad sea de 0.4 muestra que estas conexiones no son meramente producto del azar.

Figura 4. Visualización de 3 comunidades principales.



Cuadro 7. Comunidades de interés

Comunidad	Título	Canal	Grado ponderado
1	La cooptación de Walter Mazariegos en la USAC	Quorum	3

1	Qué rico come tu diputado	Quorum	3
1	Capturan a ladrón que había quedado grabado mi...	TN23 Guatemala	1
1	Bloqueos en Guatemala este 31 de agosto por al...	PrensaLibreOficial	1
2	Inician los trabajos de recuperación del Puent...	Gobierno de la República de Guatemala	2
2	Capturan a presuntos delincuentes disfrazados ...	Noti7	1
2	Conferencia de Prensa del Gobierno de Guatemal...	Gobierno de la República de Guatemala	1
3	Internet: escoger el menos malo	Quorum	3
3	Arroz con pollo a la MONOPOLIO	Quorum	3
3	Caminar en una ciudad hecha para carros	Quorum	2

Del **Cuadro 7** se tiene que la primera comunidad parece tratarse de videos que tienen que ver con robos y precios altos. La segunda comunidad parece tratarse de información de información de obras del gobierno, aunque el video del índice 6 no parece coincidir con este grupo, sino con el primeo, puede deberse al algoritmo usado. El tercer grupo parece pertenecer a noticias más variadas, no relacionadas con los temas de las otras comunidades.

A continuación, se presenta un resumen de las características de las tres comunidades; se han redondeado los valores de las dos últimas columnas.

Cuadro 8. Resumen de características de las tres comunidades principales

Comunida d	video s	canale s	autore s	comentario s	Comentario s por video	Comentario s por autor
1	4	3	187	225	52	1
2	3	2	62	84	28	1
3	3	1	29	34	11	1

A continuación, se presentan los temas más frecuentes por comunidad:

Cuadro 9. Temas frecuentes por comunidad

comunidad	Temas frecuentes
1	pueblo, dinero, diputados, trabajo, diputado
2	presidente, Guatemala, país, años, Arévalo
3	excelente, empresas, solo, internet, ley

Análisis de contenido y sentimiento

Se ha llevado el análisis sobre los datos por medio del método de sentimiento para español RoBERTuito, el cual fue preentrenado con más de 500 millones de tuits en español y luego ajustado para sentimiento con aproximadamente 5,000 tuits de TASS 2020 de distintos dialectos. Reporta tres clases: negativa (NEG), neutral (NEU) y positiva (POS), con Macro-F1 publicado de 0.705 ± 0.003 . Es más pertinente que VADER o TextBlob estándar porque estos últimos fueron diseñados principalmente para inglés.

Del análisis respecto a los comentarios, se muestra en la siguiente tabla un resumen de los resultados.

Cuadro 10. Resumen de análisis de sentimiento de comentarios

Sentimiento	Comentarios	Porcentaje
Negativo	250	61.58%
Neutro	77	18.97%
Positivo	79	19.46%

Tras el análisis usando el método descrito, se ha llegado a los siguientes hallazgos:

- **Panorama general:** la clase modal es **negativo** (61.6 %). El score medio es -0.376; por tanto, el balance agregado se interpreta como más desfavorable dentro de los comentarios recolectados, no como opinión pública.
- **Videos ($n \geq 5$):** el balance más negativo corresponde a *Bloqueos en Guatemala este 31 de agosto por alza en combustibles afectan rutas principales* ($n=7$, $\text{score}=-0.729$); el más positivo corresponde a *Plan 2032 Ciudad de Guatemala* ($n=25$, $\text{score}=0.605$). Esto describe reacciones al contenido y contexto de esos videos, no su calidad ni veracidad.

- **Canales ($n \geq 5$):** **PrensaLibreOficial** presenta el balance más negativo ($n=7$, $\text{score}=-0.729$), mientras **Municipalidad de Guatemala** presenta el más positivo ($n=25$, $\text{score}=0.605$). Los canales agrupan videos de temas y fechas diferentes, por lo que la asociación no debe atribuirse causalmente al canal.
- **Categorías ($n \geq 5$):** **News & Politics** presenta el balance más negativo ($n=335$, $\text{score}=-0.411$) y **Entertainment** el más positivo ($n=70$, $\text{score}=-0.218$). Solo dos categorías alcanzan el umbral y sus tamaños son desiguales, por lo que category funciona como una comparación amplia, no como tópico específico.
- **Comunidades:** la comunidad 1 tiene el score más negativo entre las que alcanzan el umbral ($n=225$, $\text{score}=-0.593$); la comunidad 10 tiene el más positivo ($n=25$, $\text{score}=0.605$). Sus intervalos bootstrap no incluyen cero. Estas comunidades provienen de autores compartidos y no de sentimiento; la diferencia es una caracterización posterior.
- **Incertidumbre:** 16.5 % de las predicciones tiene confianza menor a 0.60, 13.5 % fue estimado como idioma distinto de español y 11 textos fueron truncados. En los intervalos por canal, Noti7 incluye cero, mientras Quorum, Noticias Telemundo y Gobierno de Guatemala quedan del lado negativo y Municipalidad de Guatemala del positivo; esto solo resume variabilidad interna de la muestra observada.

Conclusiones

- Los autores están conectados más con otros autores que los videos con otros videos, esto puede verse desde la red bipartita donde los nodos de los autores son muchos más que los nodos de videos. Además, se observan que existen datos aislados, lo cual podría interpretarse como videos de nicho.
- Ciertos autores y videos tienen un papel clave en mantener conectadas distintas audiencias dentro de la muestra analizada.
- La primera comunidad es la que tiene más comentarios por video, tienen sentimientos negativos, no tienen un solo canal y trata principalmente de temas de corrupción y robos.
- La primera comunidad es la segunda con más comentarios por video, tienen sentimientos principalmente neutros, pero uno negativo, no tienen un solo canal y trata principalmente de información política.

- El tercer grupo tiene la menor cantidad de comentarios por video, no se identificó ningún tipo de sentimiento, solo son hechos por un canal y trata de temas varios.
- El análisis de sentimiento asigna sentimiento a todos los comentarios y conserva probabilidades para no ocultar ambigüedad. Las comparaciones permiten caracterizar videos, canales, categorías y comunidades con suficiente información, pero son descriptivas y asociativas. Los resultados deben leerse junto con los tamaños de grupo, intervalos, confianza del modelo y auditoría cualitativa; no permiten inferir causalidad ni opinión poblacional.